

# Google Play Store հավելվածների բազմաչափ վիճակագրական վերլուծություն

Աննա Բեկլարյան

Հունիս, 2026

## 1. Ներածություն և տվյալների բազայի նկարագրություն

Այս նախագծի համար ընտրվել է *Google Play Store Apps Dataset* տվյալների բազան<sup>1</sup>, որը պարունակում է տեղեկություններ **ավելի քան 10,000 Android հավելվածների** մասին, որոնք հասանելի են Google Play Store հարթակում: Տվյալների բազան ներառում է հավելվածների վերաբերյալ տարբեր բնութագրեր, ինչպիսիք են օգտատերերի գնահատականները, կարծիքների քանակը, ներբեռնումների քանակը, հավելվածի չափը, գինը և այլն:

Վիճակագրական վերլուծության նպատակով ընտրվել են հետևյալ քանակական փոփոխականները.

- **Rating** -- հավելվածի օգտատերերի միջին գնահատականը:
- **Reviews** -- օգտատերերի կարծիքների քանակը:
- **Size** -- հավելվածի չափը մեգաբայթերով (MB):
- **Installs** -- հավելվածի ներբեռնումների քանակը:
- **Price** -- հավելվածի գինը ԱՄՆ դոլարով:

Այս տվյալների բազան հետաքրքիր է վիճակագրական վերլուծության համար, քանի որ բջջային հավելվածները լայնորեն օգտագործվում են առօրյա կյանքում, իսկ դրանց հաջողությունը կարող է կախված լինել տարբեր չափերի գործոններից՝ գնահատականներից, կարծիքների քանակից, ներբեռնումներից, չափից և գնից: Տվյալների բազան հնարավորություն է տալիս ուսումնասիրել այդ գործոնների միջև առկա կապերը և հասկանալ, թե որոնք են առավելապես կապված հավելվածների հանրաճանաչության և օգտատերերի բավարարվածության հետ: Բացի այդ, ընտրված քանակական փոփոխականները հարմար են ռեգրեսիոն վերլուծության և հիմնական բաղադրիչների վերլուծության (Principal Component Analysis, PCA) կիրառման համար:

## 2. Տվյալների կառուցվածքի նախնական ուսումնասիրություն

### 2.1. Կետային ամպերի մատրից

Նախ ընտրված քանակական փոփոխականների համար կառուցվել է երկչափ կետային ամպերի մատրից: Քանի որ **Reviews** և **Installs** փոփոխականները ունեն շատ մեծ արժեքներ, գրաֆիկում օգտագործվել են դրանց լոգարիթմացված տարբերակները՝ **log\_Reviews** և **log\_Installs**: Սա թույլ է տալիս ավելի հստակ պատկերել տվյալների կառուցվածքը:

Նկար 1-ում երևում է, որ ամենահստակ դրական կապը առկա է **log\_Reviews** և **log\_Installs** փոփոխականների միջև: Սա բնական է, քանի որ շատ ներբեռնումներ ունեցող հավելվածները սովորաբար ունեն նաև ավելի շատ օգտատերերի կարծիքներ: **Rating** փոփոխականի կապը մյուս փոփոխականների հետ ավելի թույլ է, իսկ **Size** փոփոխականի դեպքում հստակ գծային կապ չի նկատվում:

<sup>1</sup><https://www.kaggle.com/datasets/lava18/google-play-store-apps>



Նկար 1. Ընտրված փոփոխականների կետային ամպերի մատրից

## 2.2. Բազմաչափ նորմալության ենթադրության գնահատում

Ստացված կետային ամպերի և անկյունագծի վրա պատկերված բաշխումների հիման վրա կարելի է գնահատել, թե որքանով է հիմնավորված բազմաչափ նորմալ բաշխման ենթադրությունը:

Նկատվում է, որ որոշ փոփոխականների բաշխումներ շեղված են, իսկ կետային ամպերը հիմնականում չունեն էլիպսաձև տեսք, որը բնորոշ է բազմաչափ նորմալ բաշխմանը: Հատկապես **Reviews**, **Installs** և **Size** փոփոխականների դեպքում նկատվում են ասիմետրիկ բաշխումներ և ոչ նորմալ կառուցվածքներ:

Հետևաբար կարելի է եզրակացնել, որ տվյալները ընդհանուր առմամբ չեն բավարարում բազմաչափ նորմալ բաշխման ենթադրությանը:

## 3. Ռեգրեսիոն վերլուծություն

Որպես ռեգրեսիայի բացատրվող փոփոխական ընտրվել է **Rating** փոփոխականը, քանի որ այն ներկայացնում է հավելվածի օգտատերերի միջին գնահատականը և բնութագրում է օգտատերերի բավարարվածության մակարդակը: Որպես բացատրող փոփոխականներ օգտագործվել են **Reviews**, **Size**, **Installs** և **Price** փոփոխականները: Քանի որ **Reviews**, **Installs** և **Price** փոփոխականներն ունեն խիստ շեղված բաշխումներ, դրանց նկատմամբ կիրառվել է լոգարիթմական ձևափոխություն:

Կառուցվել է հետևյալ բազմակի գծային ռեգրեսիայի մոդելը.

$$Rating = \beta_0 + \beta_1 \log(Reviews) + \beta_2 Size + \beta_3 \log(Installs) + \beta_4 \log(Price) + \varepsilon$$

Մոդելի պարամետրերը գնահատվել են նվազագույն քառակուսիների մեթոդով (Ordinary Least Squares, OLS).

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T Y$$

որտեղ  $X$ -ը բացատրող փոփոխականների մատրիցն է,  $Y$ -ը բացատրվող փոփոխականի վեկտորը, իսկ  $\hat{\beta}_{OLS}$ -ը գնահատված ռեգրեսիոն գործակիցների վեկտորը:

| OLS Regression Results |                  |                     |           |       |        |        |
|------------------------|------------------|---------------------|-----------|-------|--------|--------|
| =====                  |                  |                     |           |       |        |        |
| Dep. Variable:         | Rating           | R-squared:          | 0.116     |       |        |        |
| Model:                 | OLS              | Adj. R-squared:     | 0.116     |       |        |        |
| Method:                | Least Squares    | F-statistic:        | 253.6     |       |        |        |
| Date:                  | Fri, 05 Jun 2026 | Prob (F-statistic): | 4.93e-205 |       |        |        |
| Time:                  | 11:53:08         | Log-Likelihood:     | -5792.2   |       |        |        |
| No. Observations:      | 7729             | AIC:                | 1.159e+04 |       |        |        |
| Df Residuals:          | 7724             | BIC:                | 1.163e+04 |       |        |        |
| Df Model:              | 4                |                     |           |       |        |        |
| Covariance Type:       | nonrobust        |                     |           |       |        |        |
| =====                  |                  |                     |           |       |        |        |
|                        | coef             | std err             | t         | P> t  | [0.025 | 0.975] |
| -----                  |                  |                     |           |       |        |        |
| const                  | 4.6015           | 0.028               | 163.405   | 0.000 | 4.546  | 4.657  |
| log_Reviews            | 0.1653           | 0.005               | 30.109    | 0.000 | 0.155  | 0.176  |
| Size                   | -0.0002          | 0.000               | -0.869    | 0.385 | -0.001 | 0.000  |
| log_Installs           | -0.1453          | 0.005               | -26.547   | 0.000 | -0.156 | -0.135 |
| log_Price              | -0.0420          | 0.012               | -3.437    | 0.001 | -0.066 | -0.018 |
| =====                  |                  |                     |           |       |        |        |
| Omnibus:               | 2754.337         | Durbin-Watson:      | 1.820     |       |        |        |
| Prob(Omnibus):         | 0.000            | Jarque-Bera (JB):   | 13738.553 |       |        |        |
| Skew:                  | -1.651           | Prob(JB):           | 0.00      |       |        |        |
| Kurtosis:              | 8.635            | Cond. No.           | 174.      |       |        |        |

| OLS Regression Results |                  |                     |           |       |        |        |
|------------------------|------------------|---------------------|-----------|-------|--------|--------|
| =====                  |                  |                     |           |       |        |        |
| Dep. Variable:         | Rating           | R-squared:          | 0.116     |       |        |        |
| Model:                 | OLS              | Adj. R-squared:     | 0.116     |       |        |        |
| Method:                | Least Squares    | F-statistic:        | 337.9     |       |        |        |
| Date:                  | Fri, 05 Jun 2026 | Prob (F-statistic): | 3.59e-206 |       |        |        |
| Time:                  | 13:08:25         | Log-Likelihood:     | -5792.5   |       |        |        |
| No. Observations:      | 7729             | AIC:                | 1.159e+04 |       |        |        |
| Df Residuals:          | 7725             | BIC:                | 1.162e+04 |       |        |        |
| Df Model:              | 3                |                     |           |       |        |        |
| Covariance Type:       | nonrobust        |                     |           |       |        |        |
| =====                  |                  |                     |           |       |        |        |
|                        | coef             | std err             | t         | P> t  | [0.025 | 0.975] |
| -----                  |                  |                     |           |       |        |        |
| const                  | 4.5987           | 0.028               | 164.387   | 0.000 | 4.544  | 4.654  |
| log_Reviews            | 0.1644           | 0.005               | 30.549    | 0.000 | 0.154  | 0.175  |
| log_Installs           | -0.1449          | 0.005               | -26.571   | 0.000 | -0.156 | -0.134 |
| log_Price              | -0.0420          | 0.012               | -3.439    | 0.001 | -0.066 | -0.018 |
| =====                  |                  |                     |           |       |        |        |
| Omnibus:               | 2756.803         | Durbin-Watson:      | 1.820     |       |        |        |
| Prob(Omnibus):         | 0.000            | Jarque-Bera (JB):   | 13759.799 |       |        |        |
| Skew:                  | -1.653           | Prob(JB):           | 0.00      |       |        |        |
| Kurtosis:              | 8.639            | Cond. No.           | 74.2      |       |        |        |
| =====                  |                  |                     |           |       |        |        |

(ա) Սկզբնական մոդել

(բ) Փոփոխականների ընտրությունից հետո

Նկար 2. OLS ռեգրեսիայի արդյունքները փոփոխականների ընտրությունից առաջ և հետո

Սկզբնական մոդելի գնահատված հավասարումն ունի հետևյալ տեսքը.

$$\widehat{Rating} = 4.6015 + 0.1653 \log(Reviews) - 0.0002Size - 0.1453 \log(Installs) - 0.0420 \log(Price)$$

Մոդելի  $R^2$  գործակիցը հավասար է 0.116, ինչը նշանակում է, որ ընտրված բացատրող փոփոխականները միայն մասնակիորեն են բացատրում հավելվածների գնահատականների տարբերությունները: Այսինքն՝ **Rating**-ի վրա կարող են ազդել նաև այլ գործոններ, որոնք ներառված չեն տվյալ մոդելում:

Գործակիցների վերլուծությունը ցույց է տալիս, որ **log(Reviews)** փոփոխականը դրական կապ ունի **Rating**-ի հետ: Միևնույն ժամանակ, **log(Installs)** և **log(Price)** փոփոխականների գործակիցները բացասական են: **Size** փոփոխականի գործակիցը շատ փոքր է և վիճակագրորեն նշանակալի չէ ( $p = 0.385$ ), հետևաբար հավելվածի չափի ազդեցությունը գնահատականի վրա տվյալների հիման վրա չի հաստատվում:

Ընդհանուր առմամբ, մոդելը վիճակագրորեն նշանակալի է ( $F = 253.6$ ,  $p < 0.001$ ), ինչը ցույց է տալիս, որ ընտրված բացատրող փոփոխականներից առնվազն մեկը վիճակագրորեն կապված է **Rating** փոփոխականի հետ:

Քանի որ **Size** փոփոխականը վիճակագրորեն նշանակալի չէր, այն հեռացվել է մոդելից: Վերջնական մոդելի գնահատված հավասարումն է.

$$\widehat{Rating} = 4.5987 + 0.1644 \log(Reviews) - 0.1449 \log(Installs) - 0.0420 \log(Price)$$

Վերջնական մոդելի  $R^2$  գործակիցը կրկին հավասար է 0.116, ինչը ցույց է տալիս, որ **Size** փոփոխականի հեռացումը չի նվազեցրել մոդելի բացատրական կարողությունը: Վերջնական մոդելում մնացած բոլոր փոփոխականները վիճակագրորեն նշանակալի են, ուստի հետագա մեկնաբանության համար ընտրվել է այս մոդելը:

## 4. Հիմնական բաղադրիչների վերլուծություն


Հիմնական բաղադրիչների վերլուծությունը (PCA) կատարվել է ընտրված քանակական փոփոխականների վրա՝ **Rating**, **log(Reviews)**, **Size**, **log(Installs)** և **log(Price)**: Քանի որ փոփոխականները տարբեր մասշտաբներ ունեն, նախ դրանք ստանդարտացվել են:

PCA-ի նպատակն է մի քանի փոխկապակցված փոփոխականները փոխարինել նոր փոփոխականներով՝ հիմնական բաղադրիչներով, որոնք բացատրում են տվյալների տատանումների առավել մեծ մասը:

### Աղյուսակ 1. Հիմնական բաղադրիչների բացատրած տատանումները


| Բաղադրիչ | Տատանում (%) | Կուտակային (%) |
|----------|--------------|----------------|
| PC1      | 45.1         | 45.1           |
| PC2      | 20.8         | 65.8           |
| PC3      | 18.3         | 84.2           |
| PC4      | 15.1         | 99.2           |
| PC5      | 0.8          | 100.0          |

Աղյուսակ 1-ից երևում է, որ առաջին երկու հիմնական բաղադրիչները միասին բացատրում են ընդհանուր տատանումների մոտ **65.8%-ը**, իսկ առաջին երեք բաղադրիչները՝ մոտ **84.2%-ը**:



Նկար 3. PCA-ի Scree plot

Նկար 3-ը ցույց է տալիս, որ առաջին հիմնական բաղադրիչն ունի ամենամեծ բացատրական ուժը: Հինգերորդ բաղադրիչի ներդրումը շատ փոքր է, հետևաբար տվյալների հիմնական կառուցվածքը կարելի է նկարագրել առաջին մի քանի բաղադրիչների միջոցով:



Նկար 4. PCA-ի փոփոխականների կորելացիաների շրջան


Աղյուսակ 2. Առաջին երկու հիմնական բաղադրիչների բեռնվածքները

| Փոփոխական     | PC1    | PC2    |
|---------------|--------|--------|
| Rating        | -0.158 | 0.672  |
| log(Reviews)  | -0.636 | 0.022  |
| Size          | -0.374 | 0.215  |
| log(Installs) | -0.628 | -0.106 |
| log(Price)    | 0.191  | 0.700  |

Նկար 4-ում ներկայացված է փոփոխականների կորելացիաների շրջանը, իսկ Աղյուսակ 2-ում՝ առաջին երկու բաղադրիչների բեռնվածքները: **log(Reviews)** և **log(Installs)** փոփոխականները գրեթե նույն ուղղությամբ են, ինչը վկայում է դրանց միջև ուժեղ դրական կապի մասին: Մա բնական է, քանի որ շատ ներբեռնումներ ունեցող հավելվածները սովորաբար ունեն նաև շատ կարծիքներ:

Առաջին հիմնական բաղադրիչը հիմնականում կապված է **log(Reviews)** և **log(Installs)** փոփոխականների հետ, քանի որ դրանց բեռնվածքները PC1-ում մեծ են բացարձակ արժեքով: Հետևաբար PC1-ը կարելի է մեկնաբանել որպես հավելվածների հանրաճանաչության ուղղություն:

Երկրորդ հիմնական բաղադրիչը հիմնականում կապված է **Rating** և **log(Price)** փոփոխականների հետ: Մա նշանակում է, որ PC2-ը ավելի շատ արտահայտում է հավելվածի գնահատականի և գնի հետ կապված տարբերությունները:



Նկար 5. Տվյալների պրոյեկցիան առաջին երկու հիմնական բաղադրիչների վրա


Նկար 5-ում ներկայացված է հավելվածների պրոյեկցիան առաջին երկու հիմնական բաղադրիչների վրա: Յուրաքանչյուր կետ համապատասխանում է մեկ հավելվածի:

Գրաֆիկից երևում է, որ հավելվածների մեծ մասը կենտրոնացած է գրաֆիկի կենտրոնական հատվածում: Մա նշանակում է, որ ընտրված փոփոխականների տեսանկյունից հավելվածների մեծ մասը իրարից շատ կտրուկ չի տարբերվում: Միաժամանակ կան կենտրոնից հեռու գտնվող կետեր, որոնք կարելի է դիտարկել որպես առանձնացող դիտարկումներ (outliers):

Տարածվածությունն ավելի մեծ է առաջին հիմնական բաղադրիչի ուղղությամբ, ինչը բնական է, քանի որ PC1-ը բացատրում է տվյալների ընդհանուր տատանումների ավելի մեծ մասը, քան PC2-ը:

## 5. Կորելացիոն վերլուծություն

Որպես լրացուցիչ վիճակագրական մեթոդ իրականացվել է կորելացիոն վերլուծություն: Դրա նպատակն է գնահատել ընտրված քանակական փոփոխականների միջև առկա գծային կապերի ուժգնությունն ու ուղղությունը:



Նկար 6. Ընտրված փոփոխականների կորելացիոն մատրից

Նկար 6-ում ներկայացված է ընտրված փոփոխականների կորելացիոն մատրիցը: Ամենաուժեղ դրական կապը դիտվում է **log(Reviews)** և **log(Installs)** փոփոխականների միջև, որոնց կորելացիայի գործակիցը հավասար է **0.95**-ի: Սա բնական արդյունք է, քանի որ մեծ թվով ներբեռնումներ ունեցող հավելվածները սովորաբար ունեն նաև մեծ թվով օգտատերերի կարծիքներ:

**Size** փոփոխականը ցուցաբերում է չափավոր դրական կապ **log(Reviews)** ( $r = 0.38$ ) և **log(Installs)** ( $r = 0.33$ ) փոփոխականների հետ, ինչը նշանակում է, որ ավելի մեծ չափ ունեցող հավելվածները որոշ չափով հակված են ունենալ ավելի շատ ներբեռնումներ և կարծիքներ:

**Rating** փոփոխականի և մյուս փոփոխականների միջև կապերը համեմատաբար թույլ են: Ամենամեծ կորելացիան դիտվում է **log(Reviews)** փոփոխականի հետ ( $r = 0.18$ ), սակայն այն նույնպես թույլ է: Սա ցույց է տալիս, որ հավելվածի գնահատականը միայն փոքր չափով է կապված ընտրված քանակական բնութագրերի հետ:

Բացի այդ, **log(Price)** փոփոխականը ցուցաբերում է թույլ բացասական կապ **log(Reviews)** ( $r = -0.14$ ) և **log(Installs)** ( $r = -0.22$ ) փոփոխականների հետ: Այս արդյունքը կարող է վկայել այն մասին, որ ավելի թանկ հավելվածները սովորաբար ունեն ավելի քիչ ներբեռնումներ և օգտատերերի կարծիքներ:

Ընդհանուր առմամբ, կորելացիոն վերլուծությունը հաստատում է, որ տվյալների կառուցվածքում առավել կարևոր կապը գոյություն ունի **Reviews** և **Installs** փոփոխականների միջև, մինչդեռ **Rating** փոփոխականը համեմատաբար թույլ է կապված մյուս ընտրված փոփոխականների հետ:

## 6. Եզրակացություն

Այս աշխատանքում իրականացվել է Google Play Store հավելվածների բազմաչափ վիճակագրական վերլուծություն:

Երկչափ կետային ամպերի ուսումնասիրությունը ցույց տվեց, որ **log(Reviews)** և **log(Installs)** փոփոխականների միջև առկա է ուժեղ դրական կապ: Մինևույն ժամանակ, փոփոխականների բաշխումները և կետային ամպերը ցույց տվեցին, որ տվյալները ընդհանուր առմամբ չեն համապատասխանում բազմաչափ Գաուսյան բաշխմանը:

Ռեգրեսիոն վերլուծության համար որպես բացատրվող փոփոխական ընտրվել է **Rating**-ը: Ստացված մոդելը ցույց տվեց, որ **log(Reviews)**, **log(Installs)** և **log(Price)** փոփոխականները վիճակագրորեն նշանակալի են, մինչդեռ **Size** փոփոխականի ազդեցությունը նշանակալի չէ: Միաժամանակ  $R^2 = 0.116$  արժեքը ցույց է տալիս, որ գնահատականի վրա ազդում են նաև այլ գործոններ, որոնք տվյալ մոդելում ներառված չեն:

PCA-ի արդյունքները ցույց տվեցին, որ առաջին երկու հիմնական բաղադրիչները բացատրում են տվյալների ընդհանուր տատանումների մոտ **65.8%**-ը: Առաջին բաղադրիչը հիմնականում կապված է հավելվածների հանրաճանաչության հետ, իսկ երկրորդը՝ գնահատականի և գնի հետ:

Ընդհանուր առմամբ, վերլուծությունը ցույց է տալիս, որ հավելվածների ներբեռնումների և կարծիքների քանակը տվյալների կառուցվածքը ձևավորող հիմնական գործոններից են, իսկ հավելվածի գնահատականը միայն մասամբ է բացատրվում ընտրված քանակական փոփոխականներով:

## A Հավելված. Python կոդ

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm
from pandas.plotting import scatter_matrix
from pathlib import Path

BASE_DIR = Path(__file__).resolve().parents[1]
DATA_PATH = BASE_DIR / "data" / "googleplaystore.csv"
FIG_DIR = BASE_DIR / "figures"
FIG_DIR.mkdir(exist_ok=True)

def clean_size(value):
    value = str(value)
    if "M" in value:
        return float(value.replace("M", ""))
    if "k" in value:
        return float(value.replace("k", "")) / 1024
    return np.nan

def load_and_clean_data():
    df = pd.read_csv(DATA_PATH)

    df = df[df["Rating"] <= 5].copy()

    df["Reviews"] = pd.to_numeric(df["Reviews"], errors="coerce")

    df["Installs"] = (
        df["Installs"]
        .astype(str)
        .str.replace("+", "", regex=False)
        .str.replace(",", "", regex=False)
    )
    df["Installs"] = pd.to_numeric(df["Installs"], errors="coerce")

    df["Price"] = df["Price"].astype(str).str.replace("$", "", regex=False)
    df["Price"] = pd.to_numeric(df["Price"], errors="coerce")

    df["Size"] = df["Size"].apply(clean_size)

    data = df[["Rating", "Reviews", "Size", "Installs", "Price"]].dropna()

    data["log_Reviews"] = np.log1p(data["Reviews"])
    data["log_Installs"] = np.log1p(data["Installs"])
    data["log_Price"] = np.log1p(data["Price"])

    return data

def create_scatter_matrix(data):
```

```

plot_data = data[
    ["Rating", "log_Reviews", "Size", "log_Installs"]
].sample(1000, random_state=42)

scatter_matrix(
    plot_data,
    figsize=(10, 10),
    diagonal="kde",
    alpha=0.55,
    s=8,
    color="navy",
)

plt.suptitle("Scatter_Plot_Matrix_of_Google_Play_Store_Variables", fontsize=16)
plt.tight_layout()
plt.savefig(FIG_DIR / "scatter_matrix_googleplay.pdf", bbox_inches="tight")
plt.savefig(FIG_DIR / "scatter_matrix_googleplay.png", dpi=300, bbox_inches="tight")
plt.close()

```

```

def run_regression(data):
    y = data["Rating"]
    x = data[["log_Reviews", "Size", "log_Installs", "log_Price"]]
    x = sm.add_constant(x)

    model = sm.OLS(y, x).fit()
    print(model.summary())
    return model

def main():
    data = load_and_clean_data()
    print("Cleaned_data_shape:", data.shape)

    create_scatter_matrix(data)
    model = run_regression(data)

if __name__ == "__main__":
    main()

```

## B Կողի հասանելիություն

Աշխատանքում օգտագործված ամբողջ Python կոդը, Jupyter Notebook ֆայլերը և ստացված պատկերները հասանելի են հետևյալ GitHub պահոցում.

<https://github.com/AnnaBeklaryan/google-play-mv-stats>